

个人总结

在本次糖尿病并发症风险预测的数据挖掘项目中，我主要负责数据准备和随机森林模型搭建两部分工作。

数据准备阶段，我完成了数据集筛选、数据预览、冗余字段删除、缺失值分析与填充、基于 ICD-9 编码构建分类标签、特征数值编码等一系列操作。面对数据字段繁杂、核心指标缺失严重、存在异常值等问题，结合医疗业务特点选择了合适的处理方式，最终整理出格式规范、可直接用于建模的标准数据集，为后续模型训练打下了坚实基础。

随机森林模型部分，我按照分层抽样的规则划分训练集与测试集，完成模型的代码编写、训练与预测。结合临床减少漏诊的需求，将分类阈值从 0.5 调整为 0.3，随后计算准确率、召回率、AUC 等评价指标，分析模型效果与特征重要性，并整理相关实验数据和图表，配合组员完成多模型对比。

通过本次实践，我掌握了 Pandas 数据处理、缺失值可视化、特征工程等技能，也加深了对随机森林算法原理、训练流程和参数调优的理解，同时体会到数据质量对模型效果的决定性作用。

工作中我也发现自身存在不少不足：代码编写不够简洁规范，对随机森林超参数调优掌握不深入，面对样本不均衡等问题时思路比较局限，对医疗业务知识理解也较为浅显。接下来我会加强 Python 编程和机器学习算法的学习，多尝试不同的优化方案，同时结合业务场景思考问题，不断提升实操能力。

整体而言，这次项目让我收获良多，不仅锻炼了动手能力，也积累了完整的数据挖掘项目实战经验。