

个人总结

本次课程案例围绕糖尿病并发症早期风险预测模型展开，依托大数据挖掘与机器学习技术完成全流程分析建模。在小组分工里，我主要负责数据质量分析、多变量关联分析以及 Logistic 回归模型的搭建与实验工作。

在数据准备阶段，团队完成数据清洗、缺失值填充、特征编码与标签构建后，我针对处理后的数据集开展全面质量检测。借助 Python 相关工具，我依次校验了缺失值、重复值、编码合规性与数值异常值，并参照 3σ 原则筛查异常数据。结合医疗场景综合判断，数据中少量极端数值均为真实诊疗案例，不属于录入错误，无需剔除。最终验证数据集整体质量达标，各项指标均符合建模要求，为后续探索分析与模型训练提供了可靠的数据支撑。

数据探索环节，我重点完成多变量关联分析与多重共线性排查。通过计算特征相关系数、绘制热力图，我梳理出各指标之间的关联程度。结果显示，仅住院天数与用药数量、急诊次数与住院次数存在中等相关性，其余特征关联度较弱，不存在严重多重共线性问题，无需大规模删减特征。同时结合分析结果，明确了诊疗类指标和并发症的内在联系，为后续特征选用提供了参考依据。

模型构建阶段，我独立完成 Logistic 回归模型的全流程搭建。针对数据集正负样本不均衡的问题，我使用 SMOTE 过采样算法平衡样本分布，并按照 7:3 比例分层划分训练集与测试集。考虑到数据量大、特征维度多的特点，我调整迭代次数保证模型顺利收敛，完成模型训练后，结合准确率、召回率、AUC 值、ROC 曲线等指标综合评估效果。该模型拥有中等预测能力，并发症识别效果可以满足临床降低漏诊率的需求，且凭借回归系数能够直观解读各风险因子的影响方向与强弱，可用于挖掘核心致病因素。

这次案例实战让我熟悉了数据分析与机器学习建模的完整流程，也体会到技术运用必须紧密结合业务场景。我也意识到自己在模型调优、多算法综合对比上还有不足，后续我会加强相关练习，不断提升实操能力。