

## 个人总结

在本次糖尿病并发症风险预测的数据挖掘项目中，我主要负责数据探索分析以及决策树模型的搭建、优化与评估工作。

数据探索阶段，我开展了单变量分析与多变量关联分析工作。首先通过统计计算、可视化图表梳理各项指标的数据分布特征，识别数据中存在的异常值，并结合医疗场景判断数据有效性，同时对比不同特征对并发症的区分能力；还绘制了相关性热力图，分析特征之间的关联程度，排查多重共线性问题，结合分组对比探究特征与并发症的内在联系，最终梳理出核心风险指标，为后续模型训练打下坚实基础。

决策树建模阶段，我先对数据集进行样本均衡处理，再按照分层抽样规则划分训练集与测试集。完成基准模型训练后，针对模型出现的过拟合问题，采用网格搜索结合分层五折交叉验证的方式优化超参数。模型优化完成后，我开展预测工作，计算各项评价指标，结合 ROC 曲线、混淆矩阵、特征重要性以及树结构完成结果解读，整理对应的实验数据与可视化图表，积极配合组员完成多模型横向对比分析。

通过本次项目实践，我熟练掌握了数据探索、可视化分析的实操方法，对决策树算法、交叉验证以及超参数调优有了更加全面的理解，也深刻认识到前期数据分析工作会直接影响模型的最终效果。

在实操过程中，我也发现了自身存在的问题：数据分析的深度还有所欠缺，应对样本不均衡、模型优化的方案较为单一，对于医疗行业相关业务知识的理解也不够深入。在今后的学习中，我会继续深耕数据分析与机器学习相关知识，尝试更多算法优化方案，主动结合业务场景思考问题，持续提升个人实操能力。

此次完整的数据挖掘的案例，让我积累了项目实战经验，动手能力也得到了充分锻炼，整体收获颇丰。