

基于大数据挖掘与机器学习的糖尿病并发症  
早期风险预测模型研究

# 实验报告

小组成员：李海燕

黄思仪

罗璇璇

田仁雨茜

## 目录

|                              |    |
|------------------------------|----|
| 第一章 挖掘目标的定义 .....            | 1  |
| 1.1 行业背景与业务痛点 .....          | 1  |
| 1.2 核心问题定义 .....             | 1  |
| 1.3 数据范围与潜在难点 .....          | 1  |
| 1.4 研究目标与预期成果 .....          | 2  |
| 第二章 数据来源与预处理 .....           | 3  |
| 2.1 数据集来源与基本概况 .....         | 3  |
| 2.2 缺失值分析 .....              | 3  |
| 2.3 冗余字段剔除 .....             | 4  |
| 2.4 基于 ICD-9 编码构建分类标签 .....  | 5  |
| 2.5 缺失值统一处理 .....            | 5  |
| 2.6 分类特征数值编码 .....           | 6  |
| 2.7 全维度数据质量复检 .....          | 6  |
| 第三章 数据的探索性分析 .....           | 7  |
| 3.1 数据基础质量与描述性统计 .....       | 7  |
| 3.2 变量分布与异常值分析 .....         | 9  |
| 3.3 变量相关性与多重共线性排查 .....      | 10 |
| 3.4 并发症组与无并发症组分组对比分析 .....   | 11 |
| 3.5 数据探索总结 .....             | 12 |
| 第四章 模型的建立 .....              | 13 |
| 4.1 建模整体方案设计 .....           | 13 |
| 4.2 随机森林模型构建与训练 .....        | 14 |
| 4.3 Logistic 回归模型构建与训练 ..... | 16 |
| 4.4 决策树模型构建与训练 .....         | 17 |
| 第五章 模型的评估 .....              | 20 |
| 5.1 评估整体思路与核心指标 .....        | 20 |
| 5.2 各模型分项评估 .....            | 20 |
| 5.3 多模型综合对比分析 .....          | 21 |
| 第六章 模型部署与应用展望 .....          | 23 |

|                     |    |
|---------------------|----|
| 6.1 模型功能定位 .....    | 23 |
| 6.2 落地部署方案 .....    | 23 |
| 6.3 核心应用场景 .....    | 23 |
| 6.4 项目应用价值 .....    | 23 |
| 6.5 现存局限性 .....     | 24 |
| 6.6 未来优化与发展展望 ..... | 24 |

# 第一章 挖掘目标的定义

## 1.1 行业背景与业务痛点

糖尿病是全球范围内高发的慢性疾病，该类疾病引发的并发症具有发病隐匿、病情进展快、致残及致死率高等特征，已成为威胁糖尿病患者生命健康的主要因素。

现阶段国内基层慢性病管理工作存在多项突出问题：第一，糖尿病并发症早期无典型临床表现，临床筛查工作高度依赖医护人员个人经验，普遍存在漏诊率高、诊断精准度不足等问题；第二，区域医疗资源分配不均衡，基层医疗机构诊疗能力有限，难以实现并发症的早期预警与干预；第三，医疗机构长期积累了海量患者诊疗数据、生理指标数据，但数据未得到深度挖掘，并发症发病规律、核心风险因子无法有效提炼；第四，行业内缺少标准化、可量化的风险评估工具，无法依据风险等级完成患者分层管理与个性化诊疗。

基于上述现状，本研究依托大数据挖掘与机器学习技术，深度分析临床诊疗数据，挖掘糖尿病并发症的发病规律，构建具备高识别能力与可解释性的风险预测模型，搭建自动化风险预警体系，助力基层慢性病管理工作提质增效。

## 1.2 核心问题定义

本研究为二分类预测类数据挖掘项目，核心任务为：依托患者基础信息、诊疗记录、生理检验指标等多维度数据，构建机器学习预测模型，自动判别患者是否存在糖尿病并发症发病风险，实现并发症早期风险预警，支撑临床分层诊疗工作。

## 1.3 数据范围与潜在难点

### 1. 数据来源

研究数据由公开数据集与医疗机构脱敏临床数据组成，主体选用美国加州大学欧文分校（UCI）发布的 130 家美国医院糖尿病数据集（1999-2008 年）。

### 2. 数据维度

数据主要包含三大类字段：一是患者人口学基础信息，涵盖种族、性别、年

龄等；二是诊疗行为数据，包含住院时长、检查次数、用药数量、门诊及急诊就诊记录等；三是生理检验指标，包含血清葡萄糖、糖化血红蛋白等糖尿病核心检测指标。同时结合国际 ICD-9 诊断编码规则，判定患者并发症患病情况，生成模型标签。

### 3. 潜在数据难点

（1）样本分布不均衡：数据集中无并发症样本数量远高于并发症阳性样本，易导致模型偏向多数类，降低阳性样本识别能力；

（2）特征维度冗余：原始数据集共计 50 列字段，包含大量与并发症风险无关的管理类、标识类字段；

（3）核心指标缺失：血清葡萄糖、糖化血红蛋白等并发症筛查关键指标缺失比例极高，会对模型预测效果造成影响。

## 1.4 研究目标与预期成果

### 1. 细分研究目标

（1）数据处理目标：完成原始数据清洗、缺失值填充、异常值校验、特征编码等全流程预处理工作，构建标准化建模数据集；

（2）模型构建目标：选取逻辑回归、决策树、随机森林三类经典分类算法开展对比实验，结合业务需求优化模型分类阈值，降低临床漏诊率，筛选最优预测模型；

（3）落地应用目标：提炼并发症核心风险因子，输出模型判别规则，设计可落地的部署方案，实现模型在临床场景的应用。

### 2. 预期业务成果

（1）模型预测效果优于传统人工经验判断，为临床干预工作提供量化数据依据；

（2）明确糖尿病并发症核心影响因素，为慢性病健康宣教、日常管理提供支撑；

（3）依据患者风险等级实现分层管理，优化医疗资源配置，全面提升基层糖尿病慢病管理效率。

## 第二章 数据来源与预处理

### 2.1 数据集来源与基本概况

本研究选用 UCI 公开糖尿病数据集，数据集链接：

<https://archive.ics.uci.edu/dataset/296/diabetes+130-us+hospitals+for+years+1999-2008>。

数据集基础参数如下：样本总量：101766 条患者样本；原始特征数量：50 列；数据类型：包含文本分类特征、连续数值特征、ICD 诊断编码三大类；字段分类：分为患者基础信息、临床诊疗信息、生理检验指标、医院管理信息四类。

|        | encounter_id | patient_nbr | race            | gender | age     | weight | admission_type_id | discharge_disposition_id | admission_source |
|--------|--------------|-------------|-----------------|--------|---------|--------|-------------------|--------------------------|------------------|
| 0      | 2278392      | 8222157     | Caucasian       | Female | [0-10)  | ?      | 6                 | 25                       |                  |
| 1      | 149190       | 55629189    | Caucasian       | Female | [10-20) | ?      | 1                 | 1                        |                  |
| 2      | 64410        | 86047875    | AfricanAmerican | Female | [20-30) | ?      | 1                 | 1                        |                  |
| 3      | 500364       | 82442376    | Caucasian       | Male   | [30-40) | ?      | 1                 | 1                        |                  |
| 4      | 16680        | 42519267    | Caucasian       | Male   | [40-50) | ?      | 1                 | 1                        |                  |
| ...    | ...          | ...         | ...             | ...    | ...     | ...    | ...               | ...                      | ...              |
| 101761 | 443847548    | 100162476   | AfricanAmerican | Male   | [70-80) | ?      | 1                 | 3                        |                  |
| 101762 | 443847782    | 74694222    | AfricanAmerican | Female | [80-90) | ?      | 1                 | 4                        |                  |
| 101763 | 443854148    | 41086789    | Caucasian       | Male   | [70-80) | ?      | 1                 | 1                        |                  |
| 101764 | 443857166    | 31693671    | Caucasian       | Female | [80-90) | ?      | 2                 | 3                        |                  |
| 101765 | 443867222    | 175429310   | Caucasian       | Male   | [70-80) | ?      | 1                 | 1                        |                  |



101766 rows × 50 columns

Total: 101766  
Features: 50

通过初步数据探查发现，数据集存在三大问题：体重、核心生理指标缺失严重；患者编号、医保编码、用药明细等管理类字段与研究目标无关，属于冗余数据；部分字段使用符号?标识缺失，数据格式不统一。

### 2.2 缺失值分析

本研究采用 missingno 工具开展缺失值可视化分析，结合缺失相关性热力图完成综合判定。



1. 常规字段：种族、性别、年龄、住院天数等字段缺失率趋近于 0，数据完整性表现优异；

2. 高缺失核心指标：血清葡萄糖有效数据仅 5346 条，缺失率 94.7%；糖化血红蛋白有效数据仅 17018 条，缺失率 83.3%。两类指标为糖尿病并发症筛查核心指标，因此不做字段删除处理；

3. 诊断编码字段：diag\_1、diag\_2、diag\_3 存在少量缺失，缺失占比极低，不影响整体数据质量。

从缺失相关性分析结果来看,diag\_2 与 diag\_3 存在弱正相关(相关系数 0.4),仅少量样本同步缺失；血清葡萄糖与糖化血红蛋白相关系数为-0.1，两类指标缺失相互独立。综合判定，本次数据缺失属于随机非系统性缺失，并非数据采集故障导致，可采用填充方式完成处理。

## 2.3 冗余字段剔除

原始数据集包含大量标识类、管理类、无效字段，按照 “与并发症风险无关、高缺失无建模价值” 的原则完成字段剔除。剔除字段包含：患者编号、就诊 ID、体重、入院类型 ID、出院类型 ID、医保编码、专科信息、各类药物明细等。执行字段删除操作后，数据集由原始 50 列精简为 17 列，样本总量 101766 行保持不变。

|        | race            | gender | age     | time_in_hospital | num_lab_procedures | num_procedures | num_medications | number_outpatient |
|--------|-----------------|--------|---------|------------------|--------------------|----------------|-----------------|-------------------|
| 0      | Caucasian       | Female | [0-10)  | 1                | 41                 | 0              | 1               | 0                 |
| 1      | Caucasian       | Female | [10-20) | 3                | 59                 | 0              | 18              | 0                 |
| 2      | AfricanAmerican | Female | [20-30) | 2                | 11                 | 5              | 13              | 2                 |
| 3      | Caucasian       | Male   | [30-40) | 2                | 44                 | 1              | 16              | 0                 |
| 4      | Caucasian       | Male   | [40-50) | 1                | 51                 | 0              | 8               | 0                 |
| ...    | ...             | ...    | ...     | ...              | ...                | ...            | ...             | ...               |
| 101761 | AfricanAmerican | Male   | [70-80) | 3                | 51                 | 0              | 16              | 0                 |
| 101762 | AfricanAmerican | Female | [60-90) | 5                | 33                 | 3              | 18              | 0                 |
| 101763 | Caucasian       | Male   | [70-80) | 1                | 53                 | 0              | 9               | 1                 |
| 101764 | Caucasian       | Female | [60-90) | 10               | 45                 | 2              | 21              | 0                 |
| 101765 | Caucasian       | Male   | [70-80) | 6                | 13                 | 3              | 3               | 0                 |

101766 rows × 17 columns

Total: 101766  
Features: 17

## 2.4 基于 ICD-9 编码构建分类标签

本研究依托 diag\_1、diag\_2、diag\_3 三组诊断编码，结合国际 ICD-9 糖尿病并发症编码规则，构建二分类标签 has\_complication，标签定义：1=患者存在糖尿病并发症，0=患者无并发症。

编写自定义函数遍历三条诊断编码，匹配并发症编码并生成标签列，完成标签构建后，删除 diag\_1、diag\_2、diag\_3 三类原始诊断字段。处理完成后，数据集共计 15 列（包含标签列）。

## 2.5 缺失值统一处理

原始数据集采用符号?代表缺失值，结合临床业务场景，高缺失指标为核心筛查指标，不执行样本删除操作，统一采用填充方式处理：

1. 将符号?转换为标准空值 pd.NA；
2. 全局空值统一填充为 0，将数值 0 定义为 “未开展相关检查、信息未知”，贴合临床业务逻辑。



缺失值处理完成后，数据集 15 个字段均实现零缺失，数据完整性达标。

## 2.6 分类特征数值编码

数据集中包含大量文本型分类特征，机器学习模型仅支持数值型输入，因此对分类特征执行数值映射编码；原生连续数值特征保留原始数值，不做修改。具体编码规则如下表：

| 特征名称     | 编码规则                                      |
|----------|-------------------------------------------|
| 性别       | 女 = 0，男 = 1，缺失 / 未知 = 2                   |
| 种族       | 白种人= 0，非裔美国人= 1，亚裔= 2，西班牙裔= 3，其他/缺失 = 4   |
| 年龄       | [0-10)=1、[10-20)=2.....[90-100)=10，缺失 = 0 |
| 最高血清血糖   | None=0，>200=1，>300=2，正常 = 3               |
| 糖化血红蛋白结果 | None=0，>7=1，>8=2，正常 = 3                   |
| 再次入院情况   | 不入院 = 0，入院间隔 > 30 天 = 1，入院间隔 < 30 天 = 2   |

## 2.7 全维度数据质量复检

预处理工作完成后，从数据完整性、唯一性、编码合规性、异常值四个维度开展全面质量复检：

1. 数据完整性：15 个字段零缺失，满足“核心字段缺失率<5%”的行业标准；
2. 数据唯一性：重复样本 218 行，占比 0.21%，低于 5%阈值，无需处理；
3. 编码合规性：整体编码合规率高于 99.99%，仅存在 3 个不合规数值，可忽略不计；
4. 异常值：7 个字段存在统计异常值，最大占比 1.98%，均为有效重症患者数据。

复检结论：数据集各项指标均符合建模要求，数据质量合格。

## 第三章 数据的探索性分析

本章基于预处理完成的 101766 条糖尿病患者数据，通过描述性统计、分布分析、异常值检验、相关性分析及分组对比等多维度探索方法，挖掘人口学、诊疗行为、生理指标与糖尿病并发症的关联特征，识别关键风险因子，排查变量间共线性问题，为后续模型构建与并发症风险分层提供坚实的数据依据。

### 3.1 数据基础质量与描述性统计

#### 3.1.1 数据完整性与结构特征

本次探索性分析的数据集包含 15 个字段，涵盖分类特征（种族、性别、年龄、再次入院情况、并发症标签）与连续特征（住院天数、用药数量、门诊 / 急诊就诊次数、血糖、糖化血红蛋白结果等）。

数据完整性校验显示，所有字段均无缺失值，样本量为 101766 条，数据结构完整，无字段级数据缺失问题，为后续分析提供了可靠基础。

```
=== 缺失值统计 ===
种族          0
性别          0
年龄          0
住院天数      0
实验室检查次数  0
医疗操作次数  0
使用药物数量  0
门诊就诊次数  0
急诊就诊次数  0
住院次数      0
最高血清血糖  0
糖化血红蛋白结果 0
诊断总数      0
再次入院情况  0
has_complication 0
dtype: int64
```

分类变量中，并发症标签 `has_complication` 为核心二分类目标变量；连续变量覆盖了患者诊疗全流程关键指标，变量类型统一为数值型，无需额外格式转换。

#### 3.1.2 连续变量描述性统计分析

对住院天数、实验室检查次数、使用药物数量等数值指标开展描述性统计，结果如下：

分布形态与离散度：住院天数均值为 4.40 天，标准差 2.99，数据呈右偏分布，存在少量长住院周期病例；实验室检查次数均值 43.10 次，标准差 19.67，

分布跨度较大，反映不同患者检查强度差异显著。

| 指标       | count    | mean    | std   | min | 25%  | 50%  | 75%  | max   |
|----------|----------|---------|-------|-----|------|------|------|-------|
| 住院天数     | 101766.0 | 4.40    | 2.99  | 1.0 | 2.0  | 4.0  | 6.0  | 14.0  |
| 实验室检查次数  | 101766.0 | 43.10   | 19.67 | 1.0 | 31.0 | 40.0 | 54.0 | 132.0 |
| 医疗操作次数   | 101766.0 | 1.66    | 1.71  | 1.0 | 1.0  | 1.0  | 2.0  | 6.0   |
| 使用药物数量   | 101766.0 | 16.02   | 8.13  | 1.0 | 10.0 | 15.0 | 20.0 | 81.0  |
| 门诊就诊次数   | 101766.0 | 0.20    | 1.27  | 0.0 | 0.0  | 0.0  | 0.0  | 40.0  |
| 急诊就诊次数   | 101766.0 | 0.03    | 0.93  | 0.0 | 0.0  | 0.0  | 0.0  | 76.0  |
| 住院次数     | 101766.0 | 0.64    | 1.26  | 0.0 | 0.0  | 0.0  | 1.0  | 3.0   |
| 最高血清血糖   | 101766.0 | 1016.66 | 0.53  | 0.0 | 0.0  | 0.0  | 0.0  | 3.0   |
| 糖化血红蛋白结果 | 101766.0 | 4.82    | 0.83  | 0.0 | 0.0  | 0.0  | 8.0  | 9.0   |
| 诊断总数     | 101766.0 | 7.42    | 1.93  | 1.0 | 6.0  | 8.0  | 9.0  | 16.0  |


数据区间与特殊标记：门诊、急诊就诊次数均值分别为 0.20 次、0.03 次，多数样本集中在 0 值附近，呈现强偏态分布；最高血清血糖、糖化血红蛋白结果存在大量 0 值样本，为“未检测”标记，属于数据编码特征，非缺失值。

统计结果应用：通过均值、标准差、四分位数等指标，明确了各变量的数值范围与分布特征，为后续数据标准化、偏态数据校正及模型选择提供了直接依据。

### 3.2 变量分布与异常值分析

#### 3.2.1 连续变量分布可视化

通过绘制各数值变量的分布直方图，直观呈现指标分布形态：




住院天数、实验室检查次数、使用药物数量近似呈正态分布，数据主体集中在均值附近，仅少量尾部极端值；

门诊就诊次数、急诊就诊次数、最高血清血糖、糖化血红蛋白结果存在大量 0 值样本，分布高度集中，其中血糖、糖化血红蛋白的 0 值样本占比高，反映临床中部分患者未开展相关检测的实际情况；

医疗操作次数、诊断总数分布呈现明显的集中趋势，多数样本集中在低数值区间，仅少量复杂病例存在较高操作次数与诊断数量。

#### 3.2.2 异常值识别与合理性验证

通过箱线图对连续变量开展异常值检验，结果显示：




实验室检查次数、使用药物数量、门诊 / 急诊就诊次数等指标存在超出合理区间的离散点，但结合临床场景判断，这些极端值多为重症患者、多次就诊患者的真实诊疗数据，不属于录入错误；

住院天数、诊断总数的异常值多为病情复杂、合并多种并发症的病例，具备实际业务意义，无需批量剔除，可在后续建模中通过鲁棒性算法适配。

箱线图同时验证了各变量的分布离散度，进一步确认了偏态分布特征，为后续标准化方法选择、异常值处理策略提供了可视化支撑。

### 3.3 变量相关性与多重共线性排查

为避免后续建模中的多重共线性问题，对所有核心变量开展 Pearson 相关性分析，结果如下：



中等强度关联变量：住院天数与使用药物数量的相关系数为 0.47，急诊就诊次数与住院次数的相关系数为 0.27，符合临床逻辑 —— 住院时间越长、病情越复杂的患者，用药种类越多；急诊就诊频繁的患者，再次入院概率更高。

无强相关性问题：其余变量间的相关系数均低于 0.2，不存在严重多重共线性问题，后续建模无需大规模剔除变量，仅需对住院天数与用药数量进行简单处理即可，变量间独立性良好，可直接用于模型训练。


相关性热力图直观呈现了变量间的关联强度，明确了无高相关性变量对，为后续特征筛选提供了依据。

### 3.4 并发症组与无并发症组分组对比分析

以 has\_complication 为分组依据，对并发症组与无并发症组开展多维度对比分析，挖掘与并发症显著相关的特征：

#### 3.4.1 连续指标组间差异


并发症组在住院天数、使用药物数量、门诊 / 急诊就诊次数、住院次数、诊断总数等指标上的均值与中位数均高于无并发症组，其中住院天数、诊断总数、用药数量差异最为显著，反映合并并发症的患者病情更复杂，诊疗周期更长、干预措施更多；



实验室检查次数、医疗操作次数、最高血清血糖、糖化血红蛋白结果的组间差异较小，部分指标因存在大量未检测样本，区分度有限。

#### 3.4.2 分类变量与并发症的关联分析

通过交叉分布表与柱状图，分析人口学、诊疗特征与并发症的关联：



- 1. 年龄与并发症呈正相关趋势，年龄越高的患者，并发症发生占比越高；
- 2. 性别、种族间并发症占比存在小幅差异，但整体趋势稳定；
- 3. 再次入院情况与并发症关联显著，再次入院次数越多的患者，并发症发生占比越高，反映病情稳定性与并发症风险的关联。

3.5 数据探索总结

- 本章通过多维度探索性分析，明确了以下核心结论：
- 1. 数据集整体质量良好，无缺失值问题，变量分布特征清晰，偏态分布、未检测标记等数据特性已明确，为后续数据预处理提供了方向；
  - 2. 住院天数、使用药物数量、急诊就诊次数、诊断总数等指标与并发症关联显著，为后续模型构建提供了核心风险特征；
  - 3. 变量间无严重多重共线性，异常值多为临床真实数据，无需大规模剔除，建模条件良好；
  - 4. 并发症组与无并发症组的差异特征明确，为后续特征工程、模型优化及并发症风险分层提供了直接依据。
  - 5. 数据探索结果为后续模型构建指明了方向，后续将基于本次识别的核心风险特征，开展特征工程与模型训练，构建糖尿病并发症早期风险预测模型。

## 第四章 模型的建立

结合前文数据探索结果，本研究针对糖尿病并发症早期风险预测二分类任务，选取 Logistic 回归、决策树、随机森林三种经典机器学习算法开展建模实验。结合医疗场景降低漏诊率的核心需求、数据集样本不均衡、特征维度较多等特点，完成数据集划分、样本均衡处理、模型参数配置、阈值优化等工作，依次完成三类模型的搭建、训练与初步分析，为后续模型综合评估与选型奠定基础。

### 4.1 建模整体方案设计

#### 4.1.1 建模任务与评价导向

本研究属于有监督二分类任务，目标是基于患者人口学特征、诊疗指标、生理检测指标，判断患者是否发生糖尿病并发症（标签 `has_complication`: 1 = 存在并发症，0 = 无并发症）。结合基层临床筛查的实际需求，减少并发症漏诊为首要目标，因此建模过程重点关注召回率，同时兼顾准确率、精确率、F1 分数与 AUC 值等综合指标。

数据集存在明显的样本不均衡问题，无并发症样本数量远高于并发症样本，单纯依靠模型默认参数易出现模型偏向多数类、少数类识别能力不足的问题。针对该问题，本研究采用样本过采样、分类阈值调整、类别权重平衡三种方式优化模型效果。

#### 4.1.2 数据集划分规则

本次实验基于预处理完成的 101766 条有效样本、14 项特征开展建模，为保证训练集与测试集样本分布一致，避免随机划分带来的数据偏差，统一采用分层抽样方式划分数据集，保证两组数据中并发症与无并发症样本占比和原始数据集一致：

随机森林模型：按照 8:2 比例划分训练集与测试集；

Logistic 回归、决策树模型：按照 7:3 比例划分训练集与测试集；

所有模型均设置固定随机种子 `random_state=42`，保障实验结果可复现。

#### 4.1.3 通用预处理补充

在数据清洗、特征编码、缺失值填充的基础上，建模前完成两项补充处理：



一是将缺失状态统一标记为独立业务特征，不盲目删除高缺失率的血清葡萄糖、糖化血红蛋白等核心医疗指标；二是对分类特征完成数值映射，所有特征统一转为整型格式，适配三类模型输入要求。同时结合相关性分析结果，数据集中仅住院天数与用药数量存在弱相关性（相关系数 0.47），无严重多重共线性问题，无需额外剔除特征。

## 4.2 随机森林模型构建与训练

### 4.2.1 模型原理与选型依据

随机森林是基于多棵决策树的集成学习算法，具备抗异常值、泛化能力强、无需复杂特征标准化的优势，对医疗数据中存在的少量极端诊疗样本兼容性较好，适合本研究偏态分布、存在统计异常值的数据集。模型通过多棵决策树投票输出分类结果，同时可输出特征重要性，辅助挖掘并发症核心风险因子。

### 4.2.2 模型训练流程

数据载入与划分：读取预处理后数据集，分离特征集  $X$  与标签集  $y$ ，通过 `train_test_split` 按 8:2 分层划分训练集与测试集。

模型初始化：调用 `RandomForestClassifier` 构建基础随机森林模型，设置固定随机种子保证结果稳定，未额外限制树深度，采用算法默认参数完成初步训练。

概率预测与阈值优化：模型默认分类阈值为 0.5，结合临床“减少漏诊”需求，将阈值下调至 0.3，降低并发症判定门槛，提升少数类样本的召回率。核心代码实现如下：

```
[14]: # =====
# 1. 库与数据读取
# =====
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.ensemble import RandomForestClassifier
from sklearn.cluster import KMeans
from sklearn.metrics import classification_report, roc_auc_score, roc_curve

plt.rcParams['font.sans-serif'] = ['SimHei']
plt.rcParams['axes.unicode_minus'] = False

# 读取数据
df = pd.read_excel(r"C:\Users\GHS\Desktop\diabetic_data - 副本.xlsx")
X = df.drop("has_complication", axis=1)
y = df["has_complication"]

[15]: # =====
# 2. 数据集划分
# =====
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

[16]: # =====
# 3. 训练随机森林
# =====
rf = RandomForestClassifier(random_state=42)
rf.fit(X_train, y_train)

# 预测概率
rf_proba = rf.predict_proba(X_test)[:, 1]

[17]: # =====
# 4. 阈值固定 0.3 预测
# =====
threshold = 0.3
rf_pred = (rf_proba >= threshold).astype(int)
```

#### 4.2.3 模型初步结果与特征重要性分析

##### 1. 基础性能表现

阈值调整为 0.3 后，随机森林整体准确率为 0.71；无并发症样本（0 类）精确率 0.84、召回率 0.80，识别效果较好；并发症样本（1 类）精确率 0.33、召回率 0.39、F1 分数 0.36，受样本不均衡影响，对少数类识别能力偏弱；模型 AUC 值为 0.647，区分正负样本能力处于中等水平。

##### 2. 特征重要性分析

根据模型输出结果，实验室检查次数、使用药物数量、住院天数为影响糖尿病并发症的三大核心特征，重要性远高于年龄、性别、种族等人口学特征；糖化血红蛋白、血清葡萄糖等生理指标贡献度偏低。该结果与临床逻辑一致：患者诊疗频次越高、用药种类越多，并发症发生风险越高。

```
===== 随机森林（阈值0.3）结果 =====
              precision    recall  f1-score   support

     0               0.84         0.80         0.82        16211
     1               0.33         0.39         0.36         4143

 accuracy                   0.71        20354
 macro avg              0.58         0.59         0.59        20354
 weighted avg           0.73         0.71         0.72        20354

AUC: 0.647
```

## 4.3 Logistic 回归模型构建与训练

### 4.3.1 模型原理与选型依据

Logistic 回归是经典线性二分类模型，可解释性极强，通过回归系数量化每一项特征对并发症风险的影响方向与影响强度，能够精准定位关键风险因子，适合医疗领域风险归因分析。该模型计算效率高、部署轻量化，适配基层医疗系统的运行环境。

### 4.3.2 模型训练与优化策略

针对数据集样本不均衡、高维特征易导致迭代不收敛两大问题，本研究采用双重优化策略：

数据集划分：按 7:3 分层抽样划分训练集与测试集，保证样本分布均衡。

样本均衡处理：引入 SMOTE 过采样算法，对并发症少数类样本生成合成样本，平衡正负样本数量，缓解模型偏向多数类的问题。

迭代参数优化：初始化模型时设置 `max_iter=1000`，提升迭代次数，解决高维数据集下损失函数无法收敛的问题。

### 4.3.3 模型训练结果与特征系数分析

#### 1. 模型性能指标

Logistic 回归模型整体准确率为 0.5921，AUC 值 0.6297；并发症样本召回率达到 60%，有效识别出 3699 例真阳性患者，漏诊情况得到一定控制，但精确率仅 0.27，存在一定误报。

#### 2. 特征影响分析

通过回归系数判断特征对并发症风险的影响方向与强度：

正向风险特征（提升并发症概率）：诊断总数（系数 0.2677）、住院次数（0.1977）、再次入院情况（0.1704）排名前三，是主要风险诱因；性别、住院天数、门诊就诊次数、糖化血红蛋白也会小幅提升发病风险。

负向风险特征（降低并发症概率）：实验室检查次数、血清葡萄糖、年龄、急诊就诊次数等指标系数为负，对并发症发生存在微弱抑制作用。

#### 3. 决策边界分析

以诊断总数、住院次数为核心特征绘制决策边界，训练集与测试集边界趋势一致，模型无明显过拟合，泛化能力稳定。

```

===== 模型性能评估 =====
准确率: 0.5921
AUC值: 0.6297

分类报告:

```

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.85      | 0.59   | 0.70     | 24316   |
| 1            | 0.27      | 0.60   | 0.37     | 6214    |
| accuracy     |           |        | 0.59     | 30530   |
| macro avg    | 0.56      | 0.59   | 0.54     | 30530   |
| weighted avg | 0.73      | 0.59   | 0.63     | 30530   |

## 4.4 决策树模型构建与训练

### 4.4.1 模型原理与选型依据

本研究采用 CART 决策树，以基尼系数作为节点分裂依据。该模型规则透明、逻辑直观、运算成本极低，可生成树形判断规则，直接转化为临床简易筛查流程，完美适配基层医护人员使用场景；同时支持超参数精细化调优，可通过剪枝、限制树深度等方式抑制过拟合。

### 4.4.2 模型训练与超参数寻优

决策树易出现过拟合问题，且对样本不均衡敏感，因此训练分为基准模型训练与网格搜索调优两个阶段：

#### 1. 样本与数据集预处理

先通过过采样平衡正负样本，再按 7:3 分层划分训练集与测试集，最终训练集、测试集并发症样本占比均稳定在 50%。

#### 2. 基准模型搭建

初始化 `DecisionTreeClassifier`，设置 `class_weight='balanced'` 平衡类别权重，初步训练后发现基准模型存在严重过拟合（训练集准确率 0.9996，测试集准确率显著下降）。

#### 3. 网格搜索 + 5 折交叉验证调优

构建超参数网格，对树最大深度、节点最小分裂样本数、叶节点最小样本数、剪枝系数四大参数进行遍历寻优，以 AUC 值为优化目标，采用分层 5 折交叉验证保证调优结果可靠。核心参数网格与调优代码如下：

```
[9]: # 定义超参数搜索网格
param_grid = {
    'max_depth': [3, 5, 7, 9, 11], # 树的最大深度, 避免过拟合
    'min_samples_split': [2, 5, 10, 20], # 节点分裂所需最小样本数
    'min_samples_leaf': [1, 2, 5, 10], # 叶节点所需最小样本数
    'ccp_alpha': [0, 0.001, 0.005, 0.01] # 剪枝参数, 越大剪枝越狠
}

# 网格搜索+5折交叉验证
grid_search = GridSearchCV(
    estimator=DecisionTreeClassifier(criterion='gini', random_state=42, class_weight='balanced'),
    param_grid=param_grid,
    cv=StratifiedKFold(n_splits=5, shuffle=True, random_state=42),
    scoring='roc_auc', # 以AUC为优化目标
    n_jobs=-1, # 利用所有CPU核心
    verbose=1
)

# 执行网格搜索
grid_search.fit(X_train, y_train)

# 输出最优参数
print("\n==== 网格搜索完成 =====")
print(f"最优超参数: {grid_search.best_params_}")
print(f"最优交叉验证AUC值: {grid_search.best_score_:.4f}")
|
# 用最优参数构建最终模型
dt_best = grid_search.best_estimator_

# 最终模型预测
y_test_pred_best = dt_best.predict(X_test)
y_test_proba_best = dt_best.predict_proba(X_test)[:, 1]

print("\n==== 最优模型性能 =====")
print(f"测试集准确率: {accuracy_score(y_test, y_test_pred_best):.4f}")
print(f"测试集精确率: {precision_score(y_test, y_test_pred_best):.4f}")
print(f"测试集召回率: {recall_score(y_test, y_test_pred_best):.4f}")
print(f"测试集F1分数: {f1_score(y_test, y_test_pred_best):.4f}")
print(f"测试集AUC值: {roc_auc_score(y_test, y_test_proba_best):.4f}")

Fitting 5 folds for each of 320 candidates, totalling 1600 fits

==== 网格搜索完成 ====
最优超参数: {'ccp_alpha': 0, 'max_depth': 11, 'min_samples_leaf': 1, 'min_samples_split': 2}
最优交叉验证AUC值: 0.6956

==== 最优模型性能 ====
测试集准确率: 0.6429
测试集精确率: 0.6485
```

## 4. 最优模型确定

网格搜索输出最优超参数: ccp\_alpha=0、max\_depth=11、min\_samples\_leaf=1、min\_samples\_split=2, 基于该参数组合构建最终决策树模型。

### 4.4.3 模型训练结果与规则解读

#### 1. 综合性能指标

优化后的决策树测试集准确率 0.6429, 精确率 0.6485, 召回率 0.6239, F1 分数 0.6360, AUC 值达到 0.6997, 为三类单模型中综合性能最优。混淆矩阵显示, 模型对无并发症样本识别稳定性更强, 并发症样本仍存在少量漏诊, 主要受原始数据分布限制。

#### 2. 特征重要性


基尼系数计算结果显示, 住院次数为第一核心特征, 其次为医疗操作次数、实验室检查次数、诊断总数、用药数量, 五大诊疗类特征主导模型判断, 人口学与生理指标影响较弱, 与随机森林结论相互印证。

#### 3. 树形规则解读

提取决策树前三层、前五层节点规则, 模型优先以住院次数作为一级判定标准, 再依次结合医疗操作次数、诊断总数进行分层判断。整套规则清晰易懂, 无

“黑箱”问题，可直接转化为纸质筛查量表，落地于基层慢病管理。

糖尿病并发症风险预测决策树（前5层）



## 第五章 模型的评估

本章节采用多维度综合评估体系，从量化指标、混淆矩阵、ROC 曲线、特征贡献度四个维度，对三类模型的预测能力、泛化能力、可解释性进行全面评估。

### 5.1 评估整体思路与核心指标

针对医疗二分类任务与样本不均衡的特点，本研究不单一依靠准确率评判模型，综合使用准确率、精确率、召回率、F1 分数、AUC 值五大指标；结合混淆矩阵统计错判、漏判样本数量，通过 ROC 曲线判断模型整体区分能力；同时结合特征重要性、回归系数解析风险因子，兼顾模型性能与业务解读需求。

三类模型统一使用 0.3 的分类阈值，优先满足临床“降低漏诊率”的核心诉求。

### 5.2 各模型分项评估

#### 5.2.1 随机森林模型

模型核心指标：准确率 0.71、精确率 0.33、召回率 0.39、F1 分数 0.36、AUC=0.647。

从结果来看，模型整体准确率偏高，但受样本不均衡影响，模型偏向识别占比更高的无并发症样本；对并发症阳性样本的精确率、召回率偏低，识别灵敏度不足。ROC 曲线位于随机参考线上方，AUC 处于 0.5~0.7 区间，仅具备基础区分能力。

特征重要性分析显示，实验室检查次数、使用药物数量、住院天数是影响并发症风险的主要指标，与探索性分析结论保持一致。

#### 5.2.2 逻辑回归模型

模型核心指标：准确率 0.5921、精确率 0.27、召回率 0.60、F1 分数 0.37、AUC=0.6297。

模型召回率达到 60%，能够识别大部分并发症患者，漏诊控制效果较好；AUC 值处于中等水平，整体区分能力一般。通过回归系数可直观解读特征影响：诊断总数、住院次数、再次入院情况为正向高风险因素，指标数值越高，并发症发病

风险越大。

对比训练集与测试集决策边界，二者趋势基本一致，模型无明显过拟合，泛化性能稳定。

5.2.3 决策树模型

模型核心指标:准确率 0.6429、精确率 0.6485、召回率 0.6239、F1 分数 0.6360、AUC=0.6997，为三类模型中综合性能最优。

- 1. ROC 曲线分析：曲线全程位于随机猜测参考线上方，走势平稳无剧烈波动，说明模型训练稳定，具备中等偏上的样本区分能力。
- 2. 混淆矩阵分析：真实无并发症样本存在部分假阳性，真实并发症样本存在少量漏诊，该现象由原始数据集分布特性导致，属于合理误差。
- 3. 特征重要性分析：基于基尼系数计算得出，住院次数影响权重最高，其次为医疗操作次数、实验室检查次数、诊断总数、使用药物数量，五大核心指标与临床诊疗经验、前期探索分析结论高度契合。
- 4. 树结构解读：可视化树结构以住院次数为第一分裂节点，逐层结合诊断总数、医疗操作次数完成风险分层，判定逻辑清晰、规则直观，不存在机器学习“黑箱”问题，人工即可读懂筛查逻辑。

5.3 多模型综合对比分析

将三类模型核心指标汇总对比，结合性能、可解释性、落地适配性综合评价：

| 模型   | 准确率    | 精确率    | 召回率    | F1 分数 | AUC 值  | 核心优劣势                    |
|------|--------|--------|--------|-------|--------|--------------------------|
| 随机森林 | 0.71   | 0.33   | 0.39   | 0.36  | 0.647  | 整体准确率较高，阳性样本识别能力弱，可解释性差  |
| 逻辑回归 | 0.5921 | 0.27   | 0.6    | 0.37  | 0.6297 | 漏诊控制较好，泛化稳定，擅长解析特征影响关系   |
| 决策树  | 0.6429 | 0.6485 | 0.6239 | 0.636 | 0.6997 | 综合性能最优，规则透明、使用门槛低，适配基层场景 |



综合结论：

1. 受原始数据集样本不均衡、核心指标高缺失等客观因素限制，三款模型整体均处于中等预测水平；
2. 决策树综合性能与落地价值最优，兼顾识别能力与可解释性，适合作为基层临床核心筛查模型；
3. 逻辑回归可精准解析风险因子，适合作为辅助分析工具；随机森林仅作为对照模型使用。

## 第六章 模型部署与应用展望

### 6.1 模型功能定位

结合模型性能与业务场景，对三类模型进行功能划分：

1. 核心预警模型：决策树，承担日常糖尿病并发症风险筛查工作，面向基层医护人员直接使用；
2. 辅助分析模型：逻辑回归，用于长期追踪风险因子变化、开展病例统计分析；
3. 参照对比模型：随机森林，用于后续模型迭代、算法优化的横向对比。

### 6.2 落地部署方案

结合基层医疗机构信息化水平差异，设计轻量化人工应用与系统化智能应用两套落地方案，兼顾不同使用场景：

**方案一：**轻量化人工应用（适配无专业系统的基层机构）

整理决策树判定规则、核心风险指标、模型分析报告，制作成标准化筛查表单与操作说明。医护人员可对照规则，结合患者诊疗数据手动完成风险评估，无需依赖软件系统，上手简单、落地成本低。

**方案二：**系统化智能应用（适配具备医院信息系统的机构）

将决策树与逻辑回归组合模型嵌入现有医院业务系统，系统自动读取患者住院、检查、用药等数据，实时计算并发症风险概率，实现自动化早期预警，同步生成风险分析报告。

### 6.3 核心应用场景

本项目成果主要面向社区卫生服务中心、乡镇卫生院等基层医疗机构，应用于糖尿病常态化慢病管理、入院患者并发症初筛、高危人群健康随访三大场景，辅助医护人员完成患者风险分层，实现疾病早发现、早干预。

### 6.4 项目应用价值

**临床价值：**打破传统人工经验筛查模式，建立标准化、量化的风险判定规则，

减少漏诊与误诊；明确住院次数、诊疗操作、用药数量等核心风险点，指导医护人员针对性监测与干预。

**管理价值：**依据模型预测结果完成患者风险分层，合理分配医疗资源，将服务重心向高危人群倾斜，提升慢病管理精细化水平。

**技术参考价值：**针对医疗数据缺失率高、样本不均衡、要求强可解释性的特点，形成一套完整的数据挖掘与建模解决方案，可为同类慢性病风险预测项目提供参考。

## 6.5 现存局限性

**数据层面：**原始数据集正负样本不均衡问题未彻底解决，所有模型均存在一定漏诊情况；血清葡萄糖、糖化血红蛋白等核心指标缺失严重，特征信息利用不充分，制约模型精度提升。

**模型层面：**本次仅使用过采样、SMOTE 两种样本均衡策略，未对比欠采样、组合采样等方案；单棵决策树对数据非线性规律捕捉能力有限，整体预测精度未达到高端临床诊断标准。

**验证层面：**模型仅采用 5 折交叉验证，可进一步丰富验证方式，提升结果稳定性。

## 6.6 未来优化与发展展望

**数据优化：**扩充本土临床数据集，补充血糖、糖化血红蛋白等缺失指标的有效数据；尝试多种样本均衡算法，对比不同方案对模型效果的影响。

**模型迭代：**基于决策树搭建随机森林、梯度提升等集成学习模型，在保留可解释性的同时提升预测精度；扩大超参数搜索区间，结合学习曲线、验证曲线进一步缓解过拟合问题。

**应用优化：**结合区域本土患者特征微调模型参数，提升模型地域适配性；将筛查规则开发为简易小程序、移动端工具，进一步降低基层使用门槛。

**业务延伸：**基于现有风险因子开展健康宣教，针对高风险指标制定糖尿病并发症预防指导方案，实现“预测-干预-管理”全流程服务。